

Biomedical Statistics 生物医学统计

授课团队：白芳,陈洪涛



Syllabus and Notes

1. Credits: 4 (64 hours) ; 16 Weeks;
2. 1st-8th weeks: Basic Concepts and Theory; (Fang Bai 白芳)
3. 9th -16th weeks: Machine Learning and Statistics (Hongtao Chen 陈洪涛)

1. Attendance: 10%
2. Home Work: 30%
3. Final Exam: 60%

Contact Info. Of Fang Bai

Email: baifang@shanghaitech.edu.cn

Address: 人字楼B807


TA's Contact Info.

Name: 汤艺林 (主要负责1-8周)

Email: tangyl2023@shanghaitech.edu.cn

Name: 徐锐 (主要负责9-16周)

Email: xurui2022@shanghaitech.edu.cn





群聊: 2025本科生生物统计



该二维码7天内(9月22日前)有效, 重新进入将更新

Textbooks

Theory Learning



ISBN: 130526892X


ISBN-13: 9781305268920

Authors: Bernard Rosner

8th Edition

Application & Coding

Descriptive Statistics



Inferential Statistics



*“When you can **measure** what you are speaking about and **express it in numbers**, you know something about it but when you **cannot measure**, when you cannot express it in numbers, your **knowledge is of meagre** and unsatisfactory kind.”*

--Lord Kelvin

General Overview

Statistics is the Science whereby inferences are made about specific random phenomena on the basis of relatively limited sample material. The field of statistics has two major areas: **mathematical statistics** and **applied statistics**. Mathematical statistics concerns the development of new methods of statistical inference and requires detailed knowledge of abstract mathematics for its implementation. Applied statistics involves applying the methods of mathematical statistics to specific subject areas, such as economics, psychology, and public health. **Biostatistics is the branch of applied statistics** that applies statistical methods to medical and biological problems. Of course, these areas of statistics overlap somewhat. For example, in some instances, given a certain biostatistical application, standard methods do not apply and must be modified. In these circumstances, biostatisticians are involved in developing new methods.

Collecting Data, Understanding Data and Numbers

- *The Word is "Statistics" not
"Sadistics"*


Learning Goals



Basic Concepts and Theory





Computational Methods/Software



Data Analysis



Statistics and Presentation



- 🔒 What is statistics?
- 🔒 Use of statistics
- 🔒 Sampling & sample designs
- 🔒 Presentation of data
- 🔒 Measures of central tendency
- 🔒 Measures of variability
- 🔒 Normal distribution & curve
- 🔒 Probability
- 🔒 Tests of significance
- 🔒 Correlation & regression

What is Biostatistics?

- Tool of **statistics are applied** to the data that is derived from **biological sciences**
- John Graunt (1620-1674): father of health statistics
- Statistics applied to biological(life) problems, including:
 - Public health
 - Medicine
 - Ecological (生态) and environmental
- Much **more statistics** than biology, however biostatisticians must learn the biology also.



Statistical Analyses

➤ **Descriptive Statistics (描述性统计)**

- Describe the sample
- Science of collecting, summarizing, presenting

➤ **Inference (推断统计)**

- Make inferences about the population using what is observed in the sample
- Primarily performed in two ways:
 - ✓ Hypothesis testing (假设检验)
 - ✓ Estimation (估计)

What Do Biostatisticians Do?

- Identify and develop **treatment for disease** and estimate their effects.
- Identify **risk factors** for diseases.
- Design, monitor, analyze, interpret, report **results of clinical studies**.
- Develop **statistical methodologies** to address questions arising from medical/public health data.
- **Locate, define & measure extent of disease**
- **Ultimate objective -> improve the health of individual & community**



统计学基本概念介绍

一、总体与样本

总体(population): 根据研究的目的所划定范围内的**同质的个体**构成的**全体**。

总
体

有限总体

易于划分确切范围的总体

如：某城市成年男性发铅值

总体包括（**确定的时间，空间范围内**）**有限个**观察单位

无限总体

不易划分确切范围的总体

如：用酸甘焦苦合化法防治病毒性肝炎的临床实验研究

总体的同质基础是同为病毒性肝炎患者，同用酸甘焦苦合化法进行治疗，总体也包括设想的用酸甘焦苦合化法治疗的所有病毒性肝炎患者

总体是**没有时间和空间范围限制**的，因而**个体数无限**，称为无限总体

2、样本（sample）：是从总体中随机抽取一部分个体所组成的集合。

特性

可靠性 是指样本中每一个观察单位是否确属于既定的同质的总体。

代表性 是指样本是否能充分反映总体的真实情况。



总 体



样 本

样本与总体的关系

样本要具有：
代表性、随机性和可靠性。

抽样方法正确：① n 足够大
②随机抽取



统计推断方法正确



结果：

样本的统计规律性在一定程度上反映总体的统计规律性

二、同质与变异(homogeneity and variation)

研究中，除直接关注的**研究因素**外，其他**非研究因素**（如性别、年龄）也会影响研究结果，为了突出研究因素的作用，需要使各比较组之间的**非研究因素尽可能相同**，即**同质**。

即使**非研究因素控制在相同**条件下，**个体的观察值之间**也会有所不同（如双胞胎的性格、身高、体重等），这种在**同质基础上个体之间的差异**称为**变异**。

变异是统计学研究的基础，没有变异就无需统计学，**统计学正是处理数据变异的科学**。

三、误差

(1) 随机误差 (random error)

特 点：①随机误差由不确定原因引起；
②不可避免和消除；
③偏离总体的方向不能确定。

包 括：①随机测量误差 (random measurement error)

没有固定的倾向，可使多次观测结果有大有小。

②抽样误差 (sample error)

由于抽样造成的样本指标与总体指标之间的差别

(2) 系统误差 (systematic error)

由偏倚（使研究结果往一个方向偏离总体， bias）产生的错误结果，可校正和消除。


(3) 过失误差 (gross error)



由科研设计错误，或实验者的主观片面、粗心大意引起的误差。必须避免和剔除！

如：不遵守随机化分组原则、主观选取研究对象、记录错误、技术路线不清、计算错误等。

这种差错纯属责任事故，是完全不应该发生的。



四、随机事件与随机概率

(1) 随机事件 (random event):

个别试验中呈现不确定性，而大量重复试验中又具有规律性的事件。

医学上很多事件都是随机事件。如病人的疗效治愈或无效。

(2) 随机变量(random variable):

代表随机事件的变量就称为随机变量。在研究实际问题时，除遇到随机事件外，还会遇到这样的变量，即它的取值是随着试验结果的不同而变化的。

随机变量 { 离散型随机变量
 n 个患者治疗有效例数 x
连续型随机变量
 正常成年人身高

必然事件: 在一定条件下必然会发生的事件。

不可能事件: 在一定条件下必然不会发生的事件。

五、概率与频率 (probability and relative frequency)

(1) **概率**：是反映**某一事件**发生的**可能性大小**的量，统计学上常用符号 P 来表示，记为 $P(A)$ ，或 P 。 $0 \leq P(A) \leq 1$

必然事件： $P=1$ ，不可能事件概率为0；

随机事件： $0 < P < 1$ (**描述总体的特征**)

小概率事件： $P \leq 0.05$ 或 $P \leq 0.01$ 作为事物差别**有统计意义**与**有高度统计意义**的界限。

(2)频率： 对一个随机事件A作重复观察，其中某变量值出现的相对次数称为频数。若以 n 代表重复观察总次数，以 f 代表频数，则 f/n 为事件A发生的频率或相对频数。（描述样本特征）

可以证明：


若当试验次数 n 充分大以后，频率 k/n 稳定地在某一确定值 P 的附近摆动。

可用事件A的频率作为所求概率的近似值： $P(A) \approx f(A) = k/n$.


频率与概率的关系：

抛掷硬币的试验， 试验结果如下表


某试验者抛掷硬币的试验		
抛掷次数(n)	出现正面次数(k)	频率(k/n)
5	4	0.80
10	3	0.30
20	7	0.35
50	26	0.52
100	52	0.52



历史上著名的投掷硬币试验			
试验者	掷币次数 n	徽面向上频数 f	出现的频率 f/n
De Morgan	2048	1061	0.5181
Buffon	4040	2048	0.5069
Pearson	12000	6019	0.5016
Pearson	24000	12012	0.5005




(1) **统计设计**：解决在科研中如何**控制实验误差**、**改善实验有效性**与**正确分析实验结果**的关键，对专业设计布局的合理性与实验结论成立的可靠性起着重要保证作用。



原则：对照、重复、随机、盲法

(2). 收集资料 (Collection of data)

根据研究目的，实验设计的要求，收集准确的完整的充满信息的原始资料。



数据收集的原则

数据的收集是一项重要的基础工作，为了给质量管理工作提供可靠、准确的情报，搜集数据时，必须遵循以下原则：

- 1 随机抽样
- 2 数据的分层
- 3 明确数据收集的目的和方法
- 4 作好数据记录，保证数据真实、可靠、准确

● 随机抽样

定义：是指从总体抽取样品时，使每个个体被抽到的机会均等以使所抽取的样本数据能够很好地代表总体的抽样方法。

方法：鉴于实际情况产品的大小、形状、存取状态等方面的差异及条件限制，常用的随机抽样方法为：

(1) 简单随机抽样法：（单纯随机抽样）

① 抽签法（或掷骰子法）

② 随机数表法

(2) 分层随机抽样

(3) 系统随机抽样

(4) 多级随机抽样

分层随机抽样

- **定义：**将总体**按产品的某些特征**把整批产品**划分为若干层**(小批)，**同一层内**的产品质量尽可能**均匀一致**，在**各层内**分别用**简单随机抽样法**抽取一定数量的个体组成一个样本的方法
- **分层按比例随机抽样：**若按**各层在整批中所占比例**分别在各层内抽取就称为**分层按比例随机抽样**

例：某批产品批量为 $N=1600$ ，由 A 、 B 、 C 三条生产线加工而成， $N_A=800$ ， $N_B=640$ ， $N_C=160$ 。取 $n=150$ 的样本。

解：

$$n_A = 150 \times \frac{800}{1600} = 75$$

$$n_B = 60$$

$$n_C = 15$$

系统随机抽样法（间隔随机抽样）

定义：当批中产品可以按某个次序排列时，给批中每个产品编号1~N，以整数部分 $\frac{N}{n}$ 为抽样间隔，用简单随机抽样法在1至 $\left[\frac{N}{n}\right]$ 之间随机抽取的一个整数作为第一个单位产品号码，每隔 $\left[\frac{N}{n}\right]-1$ 个产品抽取一个，直到抽出n个样本为止。

例：某工序每天生产200件产品，规定巡检员在一天中抽取n=10的样本进行检查，试用系统随机抽样确定抽取的样本号码

解： $\left[\frac{N}{n}\right]=20$ ，第一个样品号码用抽签法确定为13，则被抽取的样品号码为13、33、53、...、193

多级随机抽样法

- **定义：**整批产品由**许多群**组成，每群又分**若干组**组成…，以前三种方法任一种抽取一定数量的群，该群的单位产品组成样本，称为整群抽样法或一级随机抽样法，若在各群中按随机抽样法抽取若干组组成样本，称为二阶段或二级随机抽样…

例：某产品批 $N=20000$ ，分为200箱，每箱100个，分为4盒，每盒25个，抽取 $n=100$ 的样本

解： * 从200箱中随机抽取1箱，作为样本为整群随机抽样

* 从200箱中随机抽取4箱，每箱中随机抽取1盒作为样本称为二级随机抽样

* 从200箱中随机抽取10箱，每箱中随机抽取2盒，每盒中随机抽取5个作为样本，称为

三级随机抽样

(3) 整理资料 (Sorting data)

将收集来的资料有目的，有计划地进行科学加工

对原始数据进行归纳整理，通常要做成一览表(如频数表)。

极端值：原始数据中过大或过小的值。（最高分、最低分）

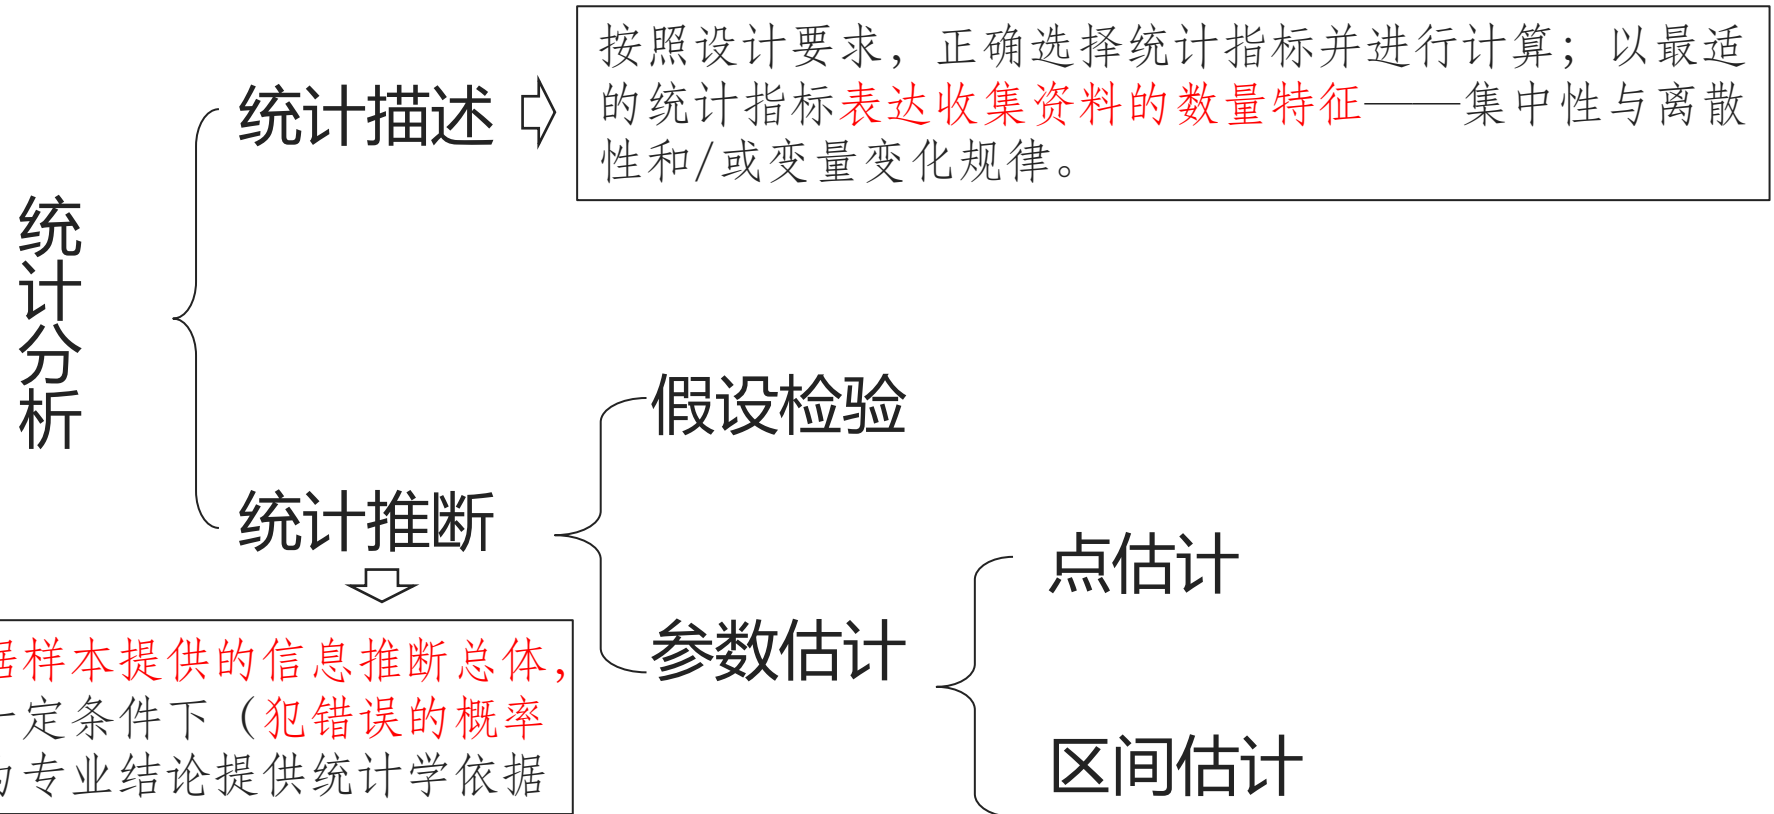
局内值：属同一总体—保留

局外值：不是属于同一总体—舍弃

(4) 分析资料 (Analysis of data)


将经过统计整理的结果，作一系列**统计描述**和**统计推断**，**阐明事物的规律性**。

采用统计分析软件，如：R、Matlab 统计包、Excel、Origin、SAS、SPSS、STATA。



统计资料的分类

数值变量资料（定量变量资料）——计量资料



(1) 数值变量资料

1、定义：

数值变量资料亦称**定量变量**资料或**计量**资料，系指用定量的方法测得某个观察单位某项指标数值所形成的资料。

如：人体医学生理指标血红蛋白（g/L）、血压(mmHg)、身高(cm)、体重(kg)等都是数值变量资料。

2、特点：

- (1) 一般带有度量衡**单位**，**数值**可带有小数，但也有的为正整数。
- (2) 可用平均数、标准差、 t 检验、 F 检验及相关与回归分析等进行分析。

(2) 分类变量资料

有序分类变量资料

1、定义：

亦称**等级资料**。是将观察单位**按某种属性**的不同程度、档次、或等级顺序**分类**，然后清点各等级所得的观察单位数。各类之间有程度的差别，给人以“**半定量**”的概念。

如肤色（黑、白）、血型（ABO）、职业（工人、医生、教师等）、性别（男女）、复方全叶马兰治疗慢性支气管炎时疗效等级分为无效、好转、显效、临控；调查某职业病对血红蛋白的影响时，将血红蛋白分为 $<90\text{g/L}$ 、 $90\text{g/L}\sim$ 、 $120\sim 160\text{ g/L}$ 、 $>160\text{g/L}$ 等。

2、特点：

- (1) 各属性间有等级关系。
- (2) 无固有计量单位
- (3) 可用率、构成比、卡方检验和秩和检验等进行分析。

无序分类变量资料

1.定义：亦称**计数资料**，是将观察单位按某种属性或类别**分组**，清点各组观察单位的个数所得的资料。

二项分类资料：按属性或类别分组时，分成相**对立的两类**。如临床疗效可分为有效和无效；再如化验结果可分为阳性和阴性。两类间互为对立。

2.**特点**：变量值是按定性的类别计数的，类与类之间**界限清楚**，数据为正整数，整理资料不易出错。

可用率、构成比、卡方检验等进行分析。

例：一组20~40岁成年人的血压


等级资料



<8	低血压
8~	正常血压
12~	轻度高血压
15~	中度高血压
17~	重度高血压



计量资料



计数资料

以12kPa为界分为正常与异常两组，统计每组例数

各类变量之间的关系

根据分析需要，各类变量资料之间可以互相转化。如测定血红蛋白的含量，计算其平均含量，此资料属数值变量资料；若将血红蛋白按正常和异常分为两类，然后清点各组人数，便成为无序变量资料中的二项分类资料；若将血红蛋白按 $<90\text{g/L}$ 、 $90\text{g/L}\sim$ 、 $120\sim 160\text{ g/L}$ 、 $>160\text{g/L}$ 分组，然后清点各等级的人数就转化为有序分类资料。

变量类型			变量值表现	实例	资料类型
数值变量			定量（具体数值）	身高（cm）	计量资料
分类变量	无序	二分类	对立的两类属性	性别（男，女）	计数资料
		多分类	不相容的多类属性	血型(A,B,O，AB)	
	有序	多分类	类间有程度差异的属性	文化程度（初中、高中、大学...）	等级资料

案例分析

案例1-2 两种药用于同一种病，A药治疗5例，4例好转；B药治疗50例，36例好转。结论是：A药优于B药。请问其结论合理吗？为什么？应该如何？

案例辨析 ① A药样本仅5例，样本含量太少；② 得出“A药优于B药”没有交待是否采用了统计学推断方法，若用目测法得出结论，则结论没有说服力；③ 未明确研究目的和研究结果将被使用的范围。

正确做法 ① 应明确研究目的和研究结果将被使用的范围，若是个别研究者或临床医生想了解这两种药的大致疗效，属于小规模的临床观察，其结论仅供少数人在今后临床实践中参考，其样本含量可能不需要很大，因为观察指标是定性的（有效、无效），一般来说，每个药物组也需要几十例（以不少于20例为宜）；若属于新药的Ⅱ期临床试验，那就要严格按有关规定，比较准确地估计出所需要的样本含量，不仅如此，还有很多严格的要求，详见本书中临床试验设计一章；② 从明确定义的总体中随机抽样进行实验研究，得到的实验结果不能仅凭数据大小作出判断，应进行假设检验，以提高结论的可信度。

案例分析

案例1-3 某研究者为了探讨原发性高血压患者肾小管早期损害的监控指标，选取尿常规、蛋白定性检查阴性，血肌酐、尿素氮均在正常范围内的原发性高血压患者74例作为病例组，其中男43例，女31例，平均年龄61岁（40~73岁）。根据高血压的病程将患者分为三组，I组高血压病期<10年，II组高血压病期10~20年，III组高血压病期>20年。另选取53名体检健康的职工为对照组。观测两组尿视黄醇结合蛋白（retinal binding protein, RBP）、微量白蛋白（microalbumin, mALB）、 β_2 微球蛋白（ β_2 microglobulin, β_2 -MG）和N-乙酰- β -D-氨基葡萄糖苷酶（N-acetyl- β -D-glucosaminidase, NAG）四项定量指标的取值。结论为：尿RBP、mALB、 β_2 -MG和NAG是原发性高血压患者肾小球、肾小管早期损害的敏感指标。请辨析这样设计实验存在什么问题？正确的做法是什么？

案例辨析 研究对象的选取在病例组和对照组之间存在不均衡性，即两组受试者之间，除了一组患有高血压，另一组未患高血压以外，在其他很多与评价高血压可能导致坏影响的方面都不一致。

对照组选取的是 53 名体检健康的职工，未明确写出平均年龄以及年龄所在的范围，也未交代性别构成情况。但由我国现行的退休制度可知，在职职工的年龄通常在 18~60 岁之间，平均年龄大约 40 岁。由临床医学基本常识可知，很多因素（比如年龄、性别等）不仅对血压有影响（通常是随着年龄的增大，血压有升高的趋势），而且对肾功能也有一定程度的影响；况且，高血压患者与健康职工还在“体力和脑力劳动强度、生活方式、心理和精神的紧张程度等诸多方面不具有可比性，而这些重要的非实验因素可能对肾功能也存在不同程度的影响。总之，原研究者所选取的病例组与对照组在很多重要的非实验因素方面（特别是年龄）不具有可比性，降低了结论的说服力。

正确做法 探讨高血压早期肾损害的监控指标，应该根据高血压患者病程所分的三个组确定受试者的年龄段，从患者所取自的人群范围内随机选取一定数量的正常健康人（而不是 仅局限再原研究者所在单位内），将正常健康人也分为响应的三个年龄段，并应尽可能确保每个年龄段中，病例组与对照组受试者在其他重要非实验因素方面（如性别构成、体力和脑力劳动强度、生活方式、心理和精神的紧张程度等）均衡一致，采用相应的统计分析方法去比较定量指标的测定结果之间的差别，其结论才有较高的可信度。

案例分析

某研究者的论文题目为“大学生身心健康状况及其影响因素研究”，以某地职业技术学院理、工、文、医学生（三年制）为研究对象，理、工、文、医学生分别挑选了60、38、19和46人，以问卷方式调查每位学生的一般健康状况、焦虑程度、抑郁程度等。得出的结论是：“大学生身心健康状况不容乐观，学业问题、就业压力、身体状况差、人际交往不良、社会支持不力为主要影响因素”。

请问其结论合理吗？为什么？应该如何？

案例辨析

- ① 样本不能代表总体。总体是“大学生”，而样本仅为某地三年制职业技术学院学生；
- ② 社会学调查的样本含量显得不足；
- ③ “理、工、文、医学生分别挑选……”这种说法中隐含人为“挑选”的意思，不符合统计学要求。

正确做法

①应在论文的题目中明确调查的时间范围和地点，还应给“大学生”下一个明确的定义，以便确定此次调查的“总体”；

②对“大学生身心健康状况”可能有影响的因素很多，应结合具体问题拟定出少数最可能有影响的因素（如学科、在学年限等）进行分层随机抽样，以保证样本有较好的代表性；

③还应根据已知条件找到估计样本含量的计算公式，不可随意确定各学科仅调查几十人；

当然，调查表中项目的设置也是十分重要的，此处从略。